Energy Detective | 建築用電異常調查 AI Agent

物聯網數據分析與應用 · Final Project Proposal

用公開電表與天氣資料，產出有依據的調查建議。

AI Agent + Domain Knowledge + Data Analytics

組員 / 學號：繳交前填入 | 2026-11-11
Proposal 階段：系統與實驗尚未完成

研究動機｜為什麼值得做？

2025 年全球用電需求約增 3%；建築占當年用電增量近 45%。

設施管理者需要從「曲線變高」判斷：要先查資料、天氣或營運排程？

公開總表可做初步調查，但不能直接確認某台設備故障。

目標：把異常訊號轉成可核對、能採取下一步行動的調查報告。

問題定義與專題範圍

使用情境

使用者：校園 / 辦公建築設施管理者。

輸入：建築 ID、期間與調查問題。

輸出：異常事件、比較基準、證據、替代解釋與查核建議。

主要限制

資料缺漏與尖峰未必是設備故障。

夜間不一定無人使用。

歷史偏離量不等於已實現節電。

MVP：公開資料歷史重播；不接控制設備。

Related Work | AI Technology（完整表見提案） 1

Ref.	Year	Problem	AI Method	Domain	Dataset	Findings	Limitation
A1	2023	工具取得外部事實	ReAct 推理 + 動作	動作與觀察	QA / 互動任務	多類任務有工具互動效益	可能重複動作；非建築
A2	2025	可解釋異常偵測	Argos 規則 + 基礎模型	標註異常模式	KPI / Yahoo等	融合規則在文中比較中改善	依賴標註；非建築
A3	2025	誤報人工複核	k-NN + 多模態LLM	曲線與背景	18個UCR子集	降低誤報伴隨漏報取捨	使用測試真值調參

Related Work | AI Technology（完整表見提案） 2

Ref.	Year	Problem	AI Method	Domain	Dataset	Findings	Limitation
A4	2025	建築時序查詢	GPT-4o + SPARQL / Python	Brick設備關係	FLEXLAB	氣流問題3/5成功	小案例；回答有遺漏
A5	2025	異常類型與解釋	Time-RA LLM / 微調	領域異常分類	RATs40K	展示分類與說明效益	AI說明非根因真值

Related Work | Domain Know-how 1

Ref.	Year	Problem	AI Method	Domain	Dataset	Findings	Limitation
D1	2026	需求為何成長	N/A 統計分析	部門、天氣	2025全球統計	建築占新增用電近45%	不能推定單棟浪費
D3	2020	公開建築基準	資料品質篩查	總表、場址、天氣	BDG2	1636建築、3053各類表	缺少設備根因標籤
D7	2020	分析的實務價值	多種EIS / FDD	監測與營運改善	104組織、6500建築	EIS/FDD節能中位3%/9%	不可外推本專題

Related Work | Domain Know-how 2

Ref.	Year	Problem	AI Method	Domain	Dataset	Findings	Limitation
D9	2025	建築模型適應	Chronos / LoRA	占用、負載、季節	SUSTIE	長上下文與微調影響表現	同棟；非故障驗證
D8	未標年	如何驗證節能	N/A 量測 / 回歸	基準與量測邊界	DOE指南	定義A–D量測驗證選項	非異常偵測實驗

Research Gap → Our Project

Existing Research：工具 Agent、建築查詢、異常偵測及文字解釋已有先例。

Limitations：資料品質、數值引用、條件假設與根因邊界仍須逐案檢查。

Research Gap：資訊有限時，如何形成完整且不過度推論的可追溯調查？

Our Project：Python 可重現分析 + 受限工具規劃 + 領域規則 + 證據檢查。

預期貢獻：調查流程、證據格式與公平比較；是否改善由實驗回答。

Deep Research Q1 | 五個核心思維

① 正常必須有條件 → 同建築、星期 / 時段與天氣的可比較基準。[D1][D8]

② 先查資料品質 → 保留 raw 與品質旗標，避免把缺值當故障。[D6]

③ 統計偏離不等於根因 → 區分觀察、假說與還缺的現場證據。[D8]

④ 分析要能支援行動 → 合併事件，列優先調查事項與可核對證據。[D7]

⑤ 公開基準不保證泛化 → 最低版本按時間切分；跨建築為擴充。[D3]

Deep Research Q2 | 三項專業取捨

1. 積極清理 ↔ 保留可疑讀值
雙方依據：cleaned減少污染，但也移除離群與零值。[D6]
共同原則：保留版本及品質旗標。
未解：沒有現場紀錄時如何區分真異常？

2. 零樣本模型 ↔ 本地調整
依據：長上下文可改善零樣本；本地微調也有幫助。[D9]
共同原則：同條件比較效果與成本。
未解：多少資料值得調整？

3. 快速篩選機會 ↔ 完成節能驗證

量化依據：實務分析支援營運改善。[D7]
保留依據：節電需要介入後量測與調整基準。[D8]

共同原則：區分偏離、機會與實際節電。
未解：多少異常負載可不影響服務而消除？

本專題：只報相對基準偏離量。

Deep Research Q3 | 十個深度理解問題

01 缺少故障標籤，如何評估事件？

02 天氣與季節改變後，異常還成立嗎？

03 raw / cleaned 會如何改變結論？

04 如何區分停館、缺值與量測故障？

05 何時應停止推論並要求補證據？

06 何時需逐棟 / 跨建築參照？

07 工具證據是否真正支持文字主張？

08 告警合併如何影響召回與查核負擔？

09 Agent 增益來自規劃、規則或表達？

10 確認根因與節電還需要哪些證據？

Agent 使用情境 | 從提問到調查

使用者：「請調查指定建築在測試期間的夜間用電是否異常。」

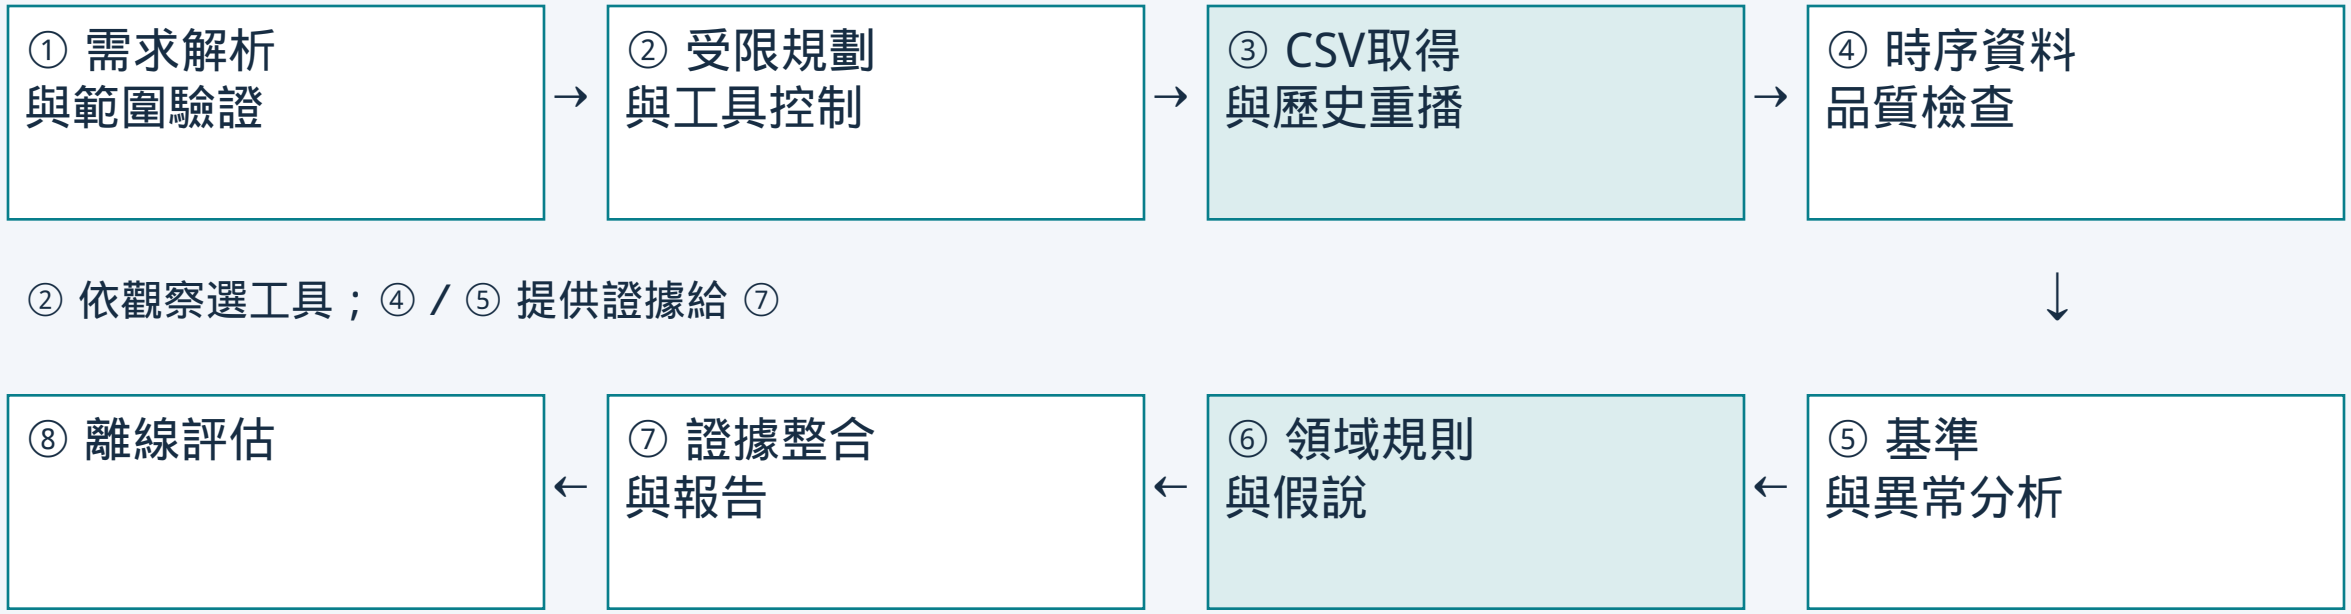
Agent 確認建築、日期及時段；不清楚的必要欄位先補問。

工具依序查資料品質與同類時段基準，必要時比較天氣與事件持續時間。

報告列出觀測值、基準、時間窗、工具證據 ID、適用規則與替代解釋。

下一步：「核對排程與使用變化」；無設備資料就不宣告空調故障。

System Architecture | 八個主要模組



輸入：使用者指定建築與期間；資料：BDG2 電表 + 天氣 + 建築資訊
⑦ 輸出可追溯報告；② 執行紀錄與 ⑦ 報告交給 ⑧ 離線評估。
各工具將結果回傳 ②，查核不足時補問使用者或停止。

資料來源與前處理

BDG2：2016–2017 每小時；1,636 建築、3,053 各類表；只取電力子集。

電表 raw/electricity.csv + weather/weather.csv + metadata/metadata.csv。

電量 kWh；依場址與時間對齊。檢查缺值、重複、零值及時間順序。

raw 也經初步整理；cleaned 已移除部分離群 / 零值，其敏感度比較列為擴充。

沒有已確認故障根因標籤；固定時間切分、保留資料版本及授權。

AI / Analytics / Domain Knowledge

Python：數值分析

品質檢查、條件基準、殘差、事件合併。

LLM：受限工具選擇

輸出結構化任務，只能呼叫已定義工具；不執行任意生成程式。

所有數值由工具結果帶入。

Domain Knowledge：明示規則

同類日 / 時段才比較。
夜間不直接等於非營運。
資料異常先分流。
總表結論不得超出量測範圍。

Report：觀察→基準→假說→缺少證據→下一步。

Flowchart | 包含分支、重試與終止條件

需求與資料範圍明確？	→	否 → 補問必要資訊 / 結束
規劃 → 檢查工具與參數	→	不合法 → 修正一次；仍錯即停止
載入資料 → 品質足夠？	→	I/O僅重試一次；品質不足即報告
分析基準、殘差與事件	→	失敗 → 保存證據與限制後停止
依觀察選用領域規則？	→	是 → 查核適用規則；否 → 記錄省略原因
領域規則 → 引用與數值檢查	→	不通過 → 固定模板；不捏造原因
保存報告與證據 → 離線評估	→	輸出 / 結束；所有失敗保留紀錄

Pseudocode | Algorithm 1 (1–23)

```
01 PROCEDURE ENERGY_DETECTIVE(question, config, replay_until)
02   INIT_GUARD(tool_budget = 10, io_retry_used = FALSE, allowed_tools)
03   manifest ← GUARDED_CALL(inspect_dataset, config.dataset_id)
04   IF failed(manifest) THEN RETURN FAILURE_WITH_LOG(manifest.error)
05   request ← PARSE_AND_VALIDATE(question, manifest)
06   IF request incomplete THEN RETURN NEED_INPUT(request.missing)
07   plan ← LLM_PLAN(request, manifest, fixed_config, dependency_constraints)
08   IF invalid(plan) THEN plan ← REPAIR_ONCE(plan)
09   IF invalid(plan) THEN RETURN FAILURE_WITH_LOG("invalid_plan")
10   data ← EXECUTE_GUARDED(plan.load_window)
11   IF transient_io_error(data) THEN data ← RETRY_ONCE_GUARDED(same_parameters)
12   IF failed(data) THEN RETURN FAILURE_WITH_LOG(data.error)
13   quality, valid ← EXECUTE_GUARDED(plan.check_quality, data_reference)
14   IF unit/time unresolved OR insufficient(valid) THEN RETURN QUALITY_REPORT(quality)
15   result ← EXECUTE_GUARDED(plan.analyze_energy, valid, fixed_config)
16   INSIDE analyze_energy:
17      train, calibration, test ← FIXED_CHRONOLOGICAL_SPLIT(valid)
18      ASSERT train ends before calibration, calibration before test, test ≤ replay_until
19      FOR method IN [GLOBAL_MEDIAN, HOUR_OF_WEEK_MEDIAN]
20         baseline ← FIT(method, train only)
21         threshold ← QUANTILE(abs(calibration.value - PREDICT(baseline)), config.q)
22         IF threshold = 0 THEN threshold ← VERIFIED_RESOLUTION_OR_FAIL()
23         residual ← test.value - PREDICT(baseline); flags ← abs(residual) > threshold
```

Pseudocode | Algorithm 1 (24–37)

```
24          events ← GROUP_CONSECUTIVE_SAME_DIRECTION(flags, sign(residual), break_on_missing = TRUE)
25          REGISTER_NUMERIC_EVIDENCE(method, events, data.source_rows)
26    IF failed(result) THEN RETURN FAILURE_WITH_LOG(result.error)
27    eligible ← RULES_ALLOWED_BY(result.events, weather, schedule, timezone)
28    next ← LLM_NEXT_STEP(plan, quality, result, eligible)
29    IF invalid(next) THEN RETURN RESTRICTED_REPORT_WITH_LOG()
30    IF next.tool = apply_domain_rules THEN rules ← EXECUTE_GUARDED(next)
31    ELSE ASSERT next.tool = build_report; RECORD_SKIPPED_RULES(next.reason)
32    evidence ← FREEZE(result, rules_if_any, quality, tool_log)
33    report ← GUARDED_CALL(build_report, question, evidence)
34    IF references_or_numbers_invalid(report) THEN report ← FIXED_TEMPLATE(evidence)
35    SAVE(report, evidence, config, tool_log)
36    RETURN report
37  END PROCEDURE
```

Experiments | 資料切分與分析 Baseline

最低版本：一棟建築、固定 12 週；8 週訓練 → 2 週校準 → 2 週測試。

B0：訓練期全域中位數；B1：訓練期同星期 / 小時中位數。

校準期絕對殘差第99百分位為暫定門檻；測試期禁止調參或重訓。

比較 MAE、資料覆蓋率及警示事件；警示數量不等於偵測準確率。

測試副本注入尖峰 / 持續增加 / 零值各10件；報命中率、漏失與延遲。

Evaluation | Agent 與公平比較

10個案例各執行3次：一般需求、資訊不足、資料缺漏、I/O失敗及無根據診斷要求。

相同案例比較：固定Python報表、固定流程 + LLM、受限工具Agent。

記錄共同資料、設定及提示詞；分開看數值分析與工具規劃的效果。

指標：任務 / 工具成功率、事實可追溯率、正確停止率、預算遵守與無依據根因數。

人工核對引用是否支持語意；同時記錄延遲與用量，不只看答案流暢度。

可行性、預期成果與交付

第1週：資料核對與品質；第2週：基準、殘差與事件分析。

第3週：Agent、規則與證據報告；第4週：比較評估與展示。

工具：Python、pandas、numpy、pydantic、單一LLM SDK；本機CSV / JSON。

Expected Outcomes：可重現原型、可核對報告與真實比較結果；本階段尚未實驗。

Proposal交付：提案、PPT、Repository、DESIGN.md。期末再完成系統與驗證。

研究問題 | 每項假設都可以被否證

RQ1：同星期 / 小時基準 B1 是否比全域中位數 B0 更符合保留期用電型態？

RQ2：Agent 能否維持資訊完整與證據正確，同時省下不必要的規則評估？

RQ3：錯 ID、錯值、錯單位、錯對象等主張，是否被驗證器拒絕或模板取代？

若固定流程相同或較佳，就照實報告；不把文字流暢當成準確或節能。

Scope | 最低版本與擴充範圍

必做：單棟 raw 資料、固定12週、B0/B1、事件、證據、十個案例。

天氣：只作同時背景；不宣稱已完成天氣校正或排除空調因素。

擴充：跨建築、cleaned敏感度、天氣預測模型、現場工單。

不在本次最低版本：實體感測器、設備控制、故障確診與已實現節電。

案例矩陣｜成功與正確停止都要驗證

C01–C03：偏高、連續零值、無警示；有證據才形成相應報告。

C04–C06：缺建築、缺期間、用電不足；補問或停止，不猜資料。

C07–C08：缺天氣仍分析用電；暫時 I/O 最多重試一次。

C09–C10：非法工具 / 越界一律拒絕；無設備證據不確診空調。

三組 × 十案例 × 三次 = 90次；合成案例明確標示，保存失敗紀錄。

證據報告｜說明用合成例

假設：4小時各觀測180 kWh，歷史基準各120 kWh，門檻30 kWh。

每點偏離60 kWh，超過門檻；合併事件的偏離總和為240 kWh。

報告：需查排程、活動與設備狀態；不能宣稱空調故障或節省240 kWh。

若中間一小時缺測：不補零、不跨缺口合併，重新計算有效事件。

人工審閱｜避免只有引用卻沒有支持

兩人獨立審閱匿名報告；先保存分歧，再討論共同判定。

逐項核對數值、單位、建築、期間、語意，不能只檢查證據 ID 存在。

完整度與追溯率一起看；沒有事實的空報告不能拿100%。

原始草稿與模板補救後結果分開；三次重跑不當成三個獨立使用者。

Final Handover | 從設計到可交接

現在：Proposal文件、簡報、DESIGN、評估協議及可重建文件流程。

期末：可執行Agent、資料版本與授權、測試、實驗結果、比較與結論。

Final PPT超過20頁；YouTube簡報與Demo超過10分鐘。

繳交前填姓名 / 學號與分工，重跑README步驟，確認其他人能接手。

References | 原始來源 1

[A1] Yao et al. (2023), ReAct. arxiv.org/html/2210.03629v3

[A2] Gu et al. (2025), Argos. arxiv.org/html/2501.14170v1

[A3] Yang et al. (2025), Refining Time Series Anomaly Detectors using LLMs. arxiv.org/html/2503.21833v1

[A4] Mulayim et al. (2025), Extraction and Analysis of Time Series Data from BAS Using LLMs. DOI: 10.20357/B73W4C

[A5] Yang et al. (2025), Time-RA. arxiv.org/html/2507.15066v1

[D1] IEA (2026), Global Energy Review 2026 — Electricity demand.

References | 原始來源 2

[D2] IEA (2026), Electricity 2026 — Demand.

[D3] Miller et al. (2020), The Building Data Genome Project 2. DOI: 10.1038/s41597-020-00712-x

[D4–D6] BUDS Lab, BDG2 repository, LICENSE, Meters data features.

[D7] Kramer et al. (2020), Proving the Business Case for Building Analytics. LBNL.

[D8] U.S. DOE FEMP, Measurement and Verification Options for Federal Energy- and Water-Saving Projects.

[D9] Park et al. (2025), Probabilistic Forecasting for Building Energy Systems using TSFMs. arxiv.org/html/2506.00630v1